

**Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«Национальный исследовательский университет ИТМО»
(Университет ИТМО)**

Факультет программной инженерии и компьютерной техники

Образовательная программа Проектирование и разработка систем больших данных 2025

Направление подготовки (специальность) 09.04.04 Программная инженерия

О Т Ч Е Т

о курсовой работе Основы Машинного Обучения

Тема задания: Исследование закономерностей в датасете Student Alcohol Consumption

Обучающийся: Баряев Андрей Алесеевич, Р4135

Руководитель практики от университета: Кугаевских Александр Владимирович

Дата 30.04.2026

Санкт-Петербург
2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
ОСНОВНАЯ ЧАСТЬ.....	3
1 Постановка задачи.....	3
1.1 Целевая переменная.....	3
1.2 Важное ограничение (утечка).....	3
1.3 Метрики.....	4
2 Данные и предобработка.....	4
2.1 Источник данных.....	4
2.2 Предобработка.....	4
3 Разведочный анализ данных (EDA).....	4
3.1 Распределения Dalc и Walc.....	4
3.2 Dalc и Walc по полу.....	5
3.3 Связь Walc со временем на учебу и пропусками.....	6
3.4 Связь Walc с оценками.....	7
4 Моделирование и сравнение алгоритмов.....	8
4.1 Результаты при пороге 0.5 (из ноутбука).....	8
4.2 Дополнительная визуализация сравнения моделей.....	9
5 Выбор финального решения: ExtraTrees.....	10
5.1 Почему выбрано ExtraTrees.....	10
5.2 ROC/PR-кривые для моделей, доступных в окружении.....	10
5.3 Подбор порога для ExtraTrees.....	11
5.4 Confusion matrix до/после подбора порога.....	12
5.5 Важность признаков ExtraTrees.....	12
6 Результаты экспериментов.....	13
6.1 Ключевые выводы.....	13
6.2. Финальная рекомендация.....	13
ЗАКЛЮЧЕНИЕ.....	13
СПИСОК ЛИТЕРАТУРЫ.....	14

ВВЕДЕНИЕ

Цель работы - построить модель бинарной классификации, предсказывающую принадлежность учащегося к группе высокого риска по потреблению алкоголя на основе косвенных социально-демографических и учебных признаков.

Практическая значимость задачи состоит в том, что в реальных условиях прямые признаки часто недоступны или нежелательны для использования, поэтому требуется прогнозировать риск по непрямым факторам.

ОСНОВНАЯ ЧАСТЬ

1 Постановка задачи

1.1 Целевая переменная

В работе использованы признаки:

- Dalc - уровень потребления алкоголя в будни (1-5),
- Walc - уровень потребления алкоголя в выходные (1-5),
- alc_mean = (Dalc + Walc) / 2.

Бинарная цель определена как:

- high_alc = 1, если alc_mean $\geq$ 3,
- high_alc = 0 иначе.

1.2 Важное ограничение (утечка)

Чтобы избежать утечки целевой информации, из признакового пространства исключены:

- Dalc,
- Walc,
- alc_mean.

Итоговая модель обучается только на косвенных признаках.

1.3 Метрики

Для оценки качества использованы:

- Recall, Precision, F1 для класса `high_alc = 1`,
- ROC-AUC,
- PR-AUC.

2 Данные и предобработка

2.1 Источник данных

Использована объединенная выборка:

- `student-mat.csv`,
- `student-por.csv`.

После вертикального объединения:

- 1044 наблюдения,
- 33 исходных признака.

2.2 Предобработка

Выполнены шаги:

1. Объединение двух датасетов в единый `DataFrame`.
2. Создание производных признаков `alc_mean` и `high_alc`.
3. One-hot кодирование категориальных признаков (`pd.get_dummies(..., drop_first=True)`).
4. Стратифицированное разделение на `train/test`:
`train_test_split(..., stratify=y, test_size=0.3, random_state=42)`.
5. Дополнительный `split` `train` на `train/val` для подбора порога вероятности.

3 Разведочный анализ данных (EDA)

3.1 Распределения `Dalc` и `Walc`




Рисунок 1. Распределение уровней потребления алкоголя в будни и выходные.

Вывод: в выходные (*Walc*) распределение смещено в сторону более высоких уровней по сравнению с буднями (*Dalc*).

3.2 Dalc и Walc по полу




Рисунок 2. Boxplot уровней *Dalc* и *Walc* в разрезе пола.

Вывод: у мужской группы медианные и верхние квартильные значения *Walc* выше.

3.3 Связь *Walc* со временем на учебу и пропусками




Рисунок 3. Scatter *studytime* vs *Walc*.



Рисунок 4. Scatter *absences* vs *Walc*.

Вывод: зависимость не является строго линейной; при большом количестве пропусков чаще встречаются повышенные уровни *Walc*.

3.4 Связь Walc с оценками




Рисунок 5. Scatter $G1$ vs $Walc$.




Рисунок 6. Scatter $G2$ vs $Walc$.




Рисунок 7. Scatter *G3* vs *Walc*.

Вывод: у наиболее высоких оценок доля наблюдений с самыми высокими уровнями *Walc* ниже.

4 Моделирование и сравнение алгоритмов

Рассмотрены модели:

- Logistic Regression (*class_weight='balanced'*),
- RandomForest (*class_weight='balanced'*),
- ExtraTrees (*class_weight='balanced'*),
- SVM RBF (*class_weight='balanced'*),
- HistGradientBoosting (*class_weight='balanced'*),
- XGBoost (*scale_pos_weight*),
- LightGBM (*class_weight='balanced'*),
- CatBoost (*auto_class_weights='Balanced'*).

4.1 Результаты при пороге 0.5 (из ноутбука)

Модель	Recall (class 1)	Precision (class 1)	F1 (class 1)	ROC-AUC	PR-AUC
Logistic Regression	0.7586	0.4272	0.5466	0.8347	0.5142
RandomForest (balanced)	0.4138	0.9600	0.5783	0.9255	0.8275
ExtraTrees (balanced)	0.7241	1.0000	0.8400	0.9406	0.8911
SVM RBF (balanced)	0.7241	0.4000	0.5153	0.8104	0.5467
HistGradientBoosting	0.7586	0.6984	0.7273	0.9095	0.8219
XGBoost	0.8103	0.6184	0.7015	0.8923	0.7370
LightGBM	0.7931	0.6571	0.7188	0.9082	0.8058
CatBoost	0.7931	0.5750	0.6667	0.8777	0.7079

4.2 Дополнительная визуализация сравнения моделей




Рисунок 8. Сводное сравнение качества всех протестированных моделей.

5 Выбор финального решения: ExtraTrees

5.1 Почему выбрано ExtraTrees

Итоговое решение принято в пользу ExtraTrees по совокупности причин:

1. Лучшая метрика F1 для целевого класса при пороге по умолчанию (0.8400).
2. Лучшие значения ROC-AUC (0.9406) и PR-AUC (0.8911) в сравнении.
3. Высокая устойчивость на табличных данных и хорошая обобщающая способность.
4. Простота воспроизводимости и интерпретации через важности признаков.
5. Адекватное время обучения на доступном объеме данных.

5.2 ROC/PR-кривые для моделей, доступных в окружении




Рисунок 9. ROC-кривые (LogReg, RF, ExtraTrees, SVM, HistGBM).




Рисунок 10. PR-кривые (LogReg, RF, ExtraTrees, SVM, HistGBM).

5.3 Подбор порога для ExtraTrees




Рисунок 11. Зависимость F1 от порога вероятности на валидации.
Оптимальный порог по валидации: ~0.32.

5.4 Confusion matrix до/после подбора порога




Рисунок 12. Матрицы ошибок ExtraTrees при порогах 0.50 и ~0.32.

Интерпретация:

- при снижении порога растет полнота (recall),
- при этом обычно снижается precision,
- итоговый баланс регулируется выбранной бизнес-целью.

5.5 Важность признаков ExtraTrees




Рисунок 13. Топ-20 наиболее значимых признаков по feature_importances_.

6 Результаты экспериментов

6.1 Ключевые выводы

1. Даже без прямых прокси-признаков (Dalc, Walc, alc_mean) модель уверенно выделяет группу риска.
2. Наилучший компромисс по метрикам показал ExtraTrees.
3. Подбор порога позволяет управлять trade-off между precision и recall без изменения модели.

6.2. Финальная рекомендация

В качестве production-кандидата в рамках данной работы рекомендуется:

- модель ExtraTreesClassifier(n_estimators=300, class_weight='balanced', random_state=42),
- рабочий порог вероятности:
- 0.50 для более консервативного сценария,
- ~0.32 для сценария, где важнее не пропускать риск.

ЗАКЛЮЧЕНИЕ

В курсовой работе выполнен полный цикл решения задачи бинарной классификации:

- подготовка данных,
- EDA,
- сравнение нескольких семейств алгоритмов,
- выбор и углубленный анализ финальной модели.

Итогом является готовое и воспроизводимое решение на ExtraTrees, дополняемое набором иллюстраций для последующей сборки финального документа.

СПИСОК ЛИТЕРАТУРЫ

1. Cortez P., Silva A. Using Data Mining to Predict Secondary School Student Performance. UCI Machine Learning Repository.
2. Документация scikit-learn: RandomForest, ExtraTrees, HistGradientBoosting, metrics.
3. Документация XGBoost, LightGBM, CatBoost.
4. Fawcett T. An introduction to ROC analysis. Pattern Recognition Letters.